

자연어처리 기말프로젝트

RAG 기반 대시보드 생성 AI

4조 (김다운, 류헤린, 이솔, 조성우, 홍예나, 황현상)

Contents

01	연구배경 및 주제
02	연구단계 별 진행상황
03	최종결과 및 시연
04	연구의의 및 한계

연구배경 및 주제



삼성전자의 2014-2024년
감사보고서 HTML 파일



금융 텍스트 분석

시계열 트렌드 분석



패턴 분석




후보 1. 금융 개체명 인식 (NER) 시스템 개발

후보 2. 금융 감정 분석 및 리스크 탐지 시스템 개발




후보 8. RAG 기반 QA 시스템

연구단계 별 진행상황



1. 파싱 및 텍스트 정규화

재무제표 부분에 대해 문서구조 반영 및 청크 단위 고도화 진행




2. 임베딩

3개의 임베딩 모델 후보군 선정 및 샘플에 대한 정확성 확인



3. ChromaDB 저장

임베딩된 문서 조각을 효율적으로 저장하고 검색할 수 있는 벡터DB



4. API 연계

질문 입력 시, API가 임베딩 및 검색해서 최종 응답을 반환하도록 연계



5. 프롬프트 설계

검색된 청크를 LLM에 전달할 때의 프롬프트 구조 최적화



6. QA 시스템 개발

질의 결과를 단순 텍스트가 아니라 표/그래프로 시각화 및 RAG 시스템 점검

1. 파싱 및 텍스트 정규화

① HTML 전처리

불필요한 태그가 많음

- 의미없는 줄바꿈, 공백 태그 다수

재무제표 표현의 문제

- (334,131)과 같이 숫자에 쉼표가 포함되거나 (~) 기호로 손실을 표시
→ LLM이 정확한 수치 인식 불가
- 의미없는 텍스트(계속;)의 반복이 계속 이어짐

구조화되어 있지 않은 HTML 구조

- 계층적이지 않고, 일관되지 않은 HTML 구조
- 원하는 섹션에서 테이블이나 텍스트를 뽑을 수가 없었음

회계기준의 변화

- 일관된 HTML 파싱이 어려움

평탄화 및 정규화

- 복잡한 HTML을 **단순하고 선형적인 텍스트 흐름**으로 변환
- 텍스트 외의 **불필요한 태그**를 모두 제거, 숫자 표기 방식 통일

섹션 구조화

- 비일관적인 계층 무시, 문서의 내용을 분석해 **태그 삽입**
- 분석에 필요없는 페이지(ex.커버) 제거

1. 파싱 및 텍스트 정규화

① HTML 전처리

```
<P style='font-weight:bold;'><BR>감사의견</P>
<P>우리는 삼성전자주식회사(이하 "회사")의 재무제표를 감사하였습니다. 동 재무제표는 2023년 12월 31일 현재의 재무상태표, 동일로 종료되는 보고기간의 손익계산서, 포괄손익계산서, 자본변동표 및
<P><BR></P>
<P>우리의 의견으로는 별첨된 회사의 재무제표는 회사의 2023년 12월 31일 현재의 재무상태와 동일로 종료되는 보고기간의 재무성과 및 현금흐름을 한국채택국제회계기준에 따라 중요성의 관점에서 공정하
<P> <BR>우리는 또한 회계감사기준에 따라, 「내부회계관리제도 설계 및 운영개념체계」에 근거한 회사의 2023년 12월 31일 현재의 내부회계관리제도를 감사하였으며, 2024년 2월 19일자 감사보고서에서
&ltP style='font-weight:bold;'>감사의견근거</P>
&ltP>우리는 대한민국의 회계감사기준에 따라 감사를 수행하였습니다. 이 기준에 따른 우리의 책임은 이 감사보고서의 재무제표감사에 대한 감사인의 책임 단락에 기술되어 있습니다. 우리는 재무제표감사와
&ltP class='PGBRK'></P>
&ltP><SPAN style='font-weight:bold;'>핵심감사사항<BR></SPAN>핵심감사사항은 우리의 전문가적 판단에 따라 당기 재무제표 감사에서 가장 유의적인 사항들입니다. 해당 사항들은 재무제표 전체
</ P>
&ltP><BR><SPAN style='text-decoration:underline;'>가. 메모리 반도체 재고자산 순실현가치 평가</SPAN><BR>
</ P>
```



```
<p>감사의견</p>
<p>우리는 삼성전자주식회사(이하 &quot;회사&quot;)의 재무제표를 감사하였습니다. 동 재무제표는 2023년 12월 31일 현재의 재무상태표, 동일로 종
<p>우리의 의견으로는 별첨된 회사의 재무제표는 회사의 2023년 12월 31일 현재의 재무상태와 동일로 종료되는 보고기간의 재무성과 및 현금흐름을 한
<p>우리는 또한 회계감사기준에 따라, 「내부회계관리제도 설계 및 운영개념체계」에 근거한 회사의 2023년 12월 31일 현재의 내부회계관리제도를 감사하였
<p>감사의견근거</p>
<p>우리는 대한민국의 회계감사기준에 따라 감사를 수행하였습니다. 이 기준에 따른 우리의 책임은 이 감사보고서의 재무제표감사에 대한 감사인의 책임
<p>핵심감사사항</p>
<p>핵심감사사항은 우리의 전문가적 판단에 따라 당기 재무제표 감사에서 가장 유의적인 사항들입니다. 해당 사항들은 재무제표 전체에 대한 감사의 관점
```

1. 파싱 및 텍스트 정규화

② JSONL 저장

크게 4가지 섹션으로 나뉘서 **감사의견**(회계법인명,핵심감사사항), **감사보고서의 별도재무제표**(재무상태표,손익계산서,포괄손익계산서,자본변동표,현금흐름표)를 파싱 후, JSONL에 저장

핵심감사사항

재무재표

주석

감사검토의견



sec1_auditor_KAM.jsonl

sec2_포괄손익계산서.jsonl

sec2_재무상태표.jsonl


sec2_자본변동표.jsonl

sec2_손익계산서.jsonl

sec2_현금흐름표.jsonl

1. 파싱 및 텍스트 정규화

청크란?



- 문서를 작은 단위(문단·표·문장 등)로 나눈 정보 블록
- 검색·임베딩·질의응답 효율을 높이는 기본 단위
- 청크를 어떻게 나누고, 어떻게 넣을지에 따라 검색의 성능이 달라짐

청크 최적화 전략

의미 단위 기준 분리

적절한 크기 설정

메타데이터 부여

중첩 슬라이딩 윈도우



의미 보강 청킹 사용



쿼리-청크 정렬 강화

LLM 친화적 전처리

1. 파싱 및 텍스트 정규화

[원본] 삼성전자 2014년 유동부채 중, 매입채무 = 4,677,527

"document" : "2014년의 삼성전자 부채에서 유동부채 중 하나인 매입채무은(는) 4677527 백만원입니다 (전기 5742116 백만원)"



해당 감사연도와 복잡한 상위항목, 하위 항목간의 관계를 넣어서
복잡한 쿼리에서도 빠르고 정확하게 탐색

1. 파싱 및 텍스트 정규화

RAG 기반 LLM의 성능과 더욱 다양한 질문에 대해 답변할 수 있도록,
삼성전자의 2014-2024년도 사업보고서 pdf 문서에서 추가 문서 및 텍스트 파싱

2016년 세계경제는 저성장 기조가 지속되는 가운데 영국의 EU탈퇴 결정, 미국 금리인상 등의 이슈들로 불확실성이 증대되었으며, 국내경제도 소비둔화, 수출부진 등 어려운 상황이 지속되었습니다.

그러나, 당사는 주요제품의 경쟁심화 속에서도 주주 여러분의 성원과 전 임직원의 노력으로 2016년 연결기준 매출 202조원, 영업이익의 29조원, 별도(본사)기준 매출 134조원, 영업이익 14조원의 견조한 실적을 달성하였습니다.

재무적인 측면에서는 연결기준 부채비율 35.9%, 자기자본비율 73.6%, ROE 12.2%,별도(본사)기준으로는 부채비율 27.1%, 자기자본비율 78.7%, ROE 8.5% 등 건실한 재무구조를 지속 유지하였으며, 2016년 브랜드 가치는 14% 증가한 518억불로 3년연속 세계 전체 기업 중 7위('16년 10월 인터브랜드 발표 기준)를 차지하였습니다.

사업 측면에서는 .핵심기술 역량을 바탕으로 세계 최초 10나노급 DRAM 제품을 출시하였으며, 차별화된 화질 및 디자인 경쟁력을 바탕으로 한 SUHD TV 및 Curved TV의 판매 확대 로 시장지배력 및 업계리더십을

2017년은 미국의 신 행정부 출범 협상에 따른 EU 결속력 약화 등 당사의 주력제품은 경쟁이 더욱 협이 될 것으로 보입니다.

당사는 급변하는 경영환경과 어려 하고, 전략적 M&A 및 R&D를 통 을 기울이겠습니다.



```
{
  "id": "사업보고서-2016-경영진의견",
  "document": "[개요] 2016년 세계경제는 저성장 기조가 지속되는 가운데 영국의 EU탈퇴 결정, 미국 금리 인상 등의 이슈들로 불확실성이 증대되었으며... 삼 전략적 M&A 및 R&D를 통해 신수종 사업의 발굴 및 육 성으로 미래기회 선점에 총력을 기울이겠습니다.",
  "metadata": {
    "year": 2016,
    "source": "경영진의견 _2016.pdf",
    "section": "경영진의견-개요"
  }
}
```

구 분		주식의 종류	제46기	제45기	제44기
주당액면가액 (원)			5,000	5,000	5,000
(연결)당기순이익(백만원)			23,082,499	29,821,215	23,185,375
주당순이익 (원)			153,105	197,841	154,020
현금배당금총액 (백만원)			2,999,972	2,156,969	1,206,562
주식배당금총액 (백만원)			-	-	-
(연결)현금배당성향(%)			13.0	7.2	5.2
현금배당수익률 (%)	보통주		1.5	1.0	0.5
	우선주		1.9	1.4	1.0
주식배당수익률 (%)	보통주		-	-	-
	우선주		-	-	-
주당 현금배당금 (원)	보통주		20,000	14,300	8,000
	우선주		20,050	14,350	8,050
주당 주식배당 (주)	보통주		-	-	-
	우선주		-	-	-



배당 정보 - 2019년

| 구 분 | 주식의 종류 | 2019년 | 2018년 | 2017년 |

|:-----|:-----|:-----|:-----|:-----|

| 주당액면가액(원) || 100 | 100 | 100 |

| (연결)당기순이익(백만원) || 21505054 | 43890877 | 41344569 |

| (별도)당기순이익(백만원) || 15353323 | 32815127 | 28800837 |

| (연결)주당순이익(원) || 3166 | 6461 | 5997 |

| 현금배당금총액(백만원) || 9619243 | 9619243 | 5826302 |

| 주식배당금총액(백만원) || || |

| (연결)현금배당성향(%) || 44.7 | 21.9 | 14.1 |

| 현금배당수익률(%) | 보통주 | 2.6 | 3.7 | 1.7 |

|| 우선주 | 3.1 | 4.5 | 2.1 |

| 주식배당수익률(%) | 보통주 || |

|| 우선주 || |

| 주당 현금배당금(원) | 보통주 | 1416 | 1416 | 850 |

|| 우선주 | 1417 | 1417 | 851 |

| 주당 주식배당(주) | 보통주 || |

|| 우선주 || |

추가 텍스트 파싱

[감사보고서]

- 우리 → 회계법인 명
- 회사 → 삼성전자

[사업보고서]

- 당사 → 삼성전자

2. 임베딩

3가지 임베딩 모델을 적용하고, 정량적 평가를 통해 최종 임베딩 모델을 선정함

1. E5

- MS Research에서 개발한 범용 임베딩 모델
- 다국어 지원, 문서 검색/질의응답 등 다양한 태스크에서 안정적 성능
- Open source로 확장성 높음


2. KoE5

- E5를 한국어 데이터에 맞게 학습한 버전
- 한국어 문서 검색·QA에 특화되어 높은 성능
- 한국어 재무제표, 보고서 같은 도메인 텍스트에 특히 유리하고, prompt tuning 효과 높음

3. Open AI

- OpenAI API에서 제공하는 최신 LLM 기반 상용 임베딩 모델
- 영어 기준으로 매우 강력한 성능, 다양한 언어도 지원
- 대규모 사전학습으로 일반적 질의응답/추천 시스템에 활용도 높음

2. 임베딩



*MRR(Mean Reciprocal Rank) : 검색이나 추천 시스템이 “얼마나 정답을 높은 순위에 보여주는지”를 측정하는 성능지표

**골든셋 : 직접 질문과 정답 50쌍을 만들어 chromadb와 LLM의 결과를 검증

2. 임베딩

① 골든셋 구축

감사의견, 손익계산서, 재무상태표 등 문항 비율을 동일하게 유지하여 특정 문서 유형에 대한 편향을 최소화

띄어쓰기, 동의어, 유사 표현 등을 활용한 문장 형태의 질문을 구성 예) 회계법인은? → 감사를 담당한 곳은?

서술형과 수치형 질문을 모두 포함 예) 2023년 핵심감사사항은? 2015년 보통주 자본금은 얼마인가?

특정 연도의 정보를 묻는 질문과 여러 연도를 비교하는 질문을 혼합 예) 최근 6년동안 발행 주식 총액은?

answers

정답 문서의 고유 ID를 저장
(chromadb의 ID와 비교)



values

실제 정답 내용
(숫자, 텍스트)을 저장

2. 임베딩

㉔ MRR 계산

Q. 최근 2년 동안 매출 총이익은?

1. 2024년 매출 총이익은 ..	RR = 1 / 1
2.	
3.	
4. 2023년 매출 총이익은 ..	RR = 1 / 4
5.	
6.	
7.	
8.	
9.	
10.	

$$\text{MRR} = (1 + 0.25) / 2 = 0.625$$

X 50 문항 → 50개의 MRR → /50 → MRR 평균

$$\text{MRR} = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{\text{rank}_i}$$

Mean reciprocal rank

2. 임베딩

㉔ MRR 계산

표준 MRR 계산방식

- 가장 먼저 찾은 정답의 순위만을 평가에 반영
- 최고 점수 1

현재 MRR 계산방식

- 모든 정답의 순위를 점수에 반영하여 평균을 내는 방식
- 최고 점수 1이 되지 못함




- ✓ 질의와 관련된 모든 유효한 정보 → 상위 순위에 제시
- ✓ 기존 방식은 여러 정답 중 하나만 높은 순위에 있으면 높은 점수 부여 → 성능 과대평가 문제

2. 임베딩

③ 최종모델 선정

모델	dense 검색만
E5	0.6165
KoE5	0.6160
OpenAI	0.4510
all-MiniLM-L6-v2 (ChromaDB default)	0.0729



MRR 평균으로는 koE5와 E5의 우열을 가릴 수가 없음 → Top10 결과에 정답이 포함되어있는 비율 비교
E5는 86.3%, KoE5는 81%이기 때문에 **최종 모델은 E5로 선정**


2. 임베딩

④ 다단계 검색 파이프라인 도입




1차 검색(Retrieval)

- 사용자 질문을 ChromaDB에 전달하여 벡터 검색 실행
- 질문과 의미적으로 관련성 높은 초기 후보군(15-20개) 확보



2차 정렬(Rerank)


- 1차 후보군과 원본 질문의 문맥적 관련성을 심층 분석하여 **순위 정밀 재조정**
- Cross-Encoder 모델 (BAAI/bge-reranker-v2-m3) 활용



최종 점수화(Boosting)

- 사용자 질문에서 핵심 메타데이터(연도, 표 헤더 등) 추출
- **Soft-filtering: Rerank 순위 기준**으로, 추출한 메타데이터와 일치하는 문서에 보너스 점수 부여
- 최종 점수
= Reranker Score + Metadata Bonus

3. ChromaDB 저장



**

company	회사명
year	연도
section	섹션 종류 • ex. 재무상태표, 손익계산서
section_path	문서 내의 위치 • ex. KAM > 수익인식
section_name	섹션 상세명 • ex. 수익인식

4. LLM 모델

Qwen/Qwen2.5-1.5B-Instruct



- 알리바바에서 개발한 Open - Source LLM
- Multilingual 모델로, 한국어 성능 준수
- 수학과 코딩 분야에 특화됨

llama3-Instruct



- 메타에서 개발한 Open - weight LLM
- Rejection sampling, PPO 기반 파인튜닝
- decoder-only 아키텍처

GPT-4o



- OpenAI API
- 추론·코딩 성능 우수
- 한국어 품질 우수, 장문 생성에 강함

4. LLM 모델

평가기준	Gpt-4o	Llama3	QWEN
사실정확성	우수 원본의 모든 수치 인용	미흡 환각현상 발생	우수 원본의 모든 수치 인용
정보포함률	미흡 부문별 경영진 의견 누락 발생	미흡 DS(반도체) 부문 전체 누락	미흡 경영진의견의 사업부문누락
가독성 및 구조	우수 리포트 양식으로 잘 생성, 마크다운 생성	미흡 단락이 구분되지만, 줄글 위주 생성 → 가독성 저하	미흡 긴 글 생성 불가 → 요약만 가능
요약의 질 (분석)	우수 프롬프트에서 요청한 만큼 분석함	미흡 재무수치만 나열함	우수 한줄로 간단히 요약
문맥의 적절성	우수 객관적인 분석 리포트 내용	미흡 경영진의 의견을 그대로 인용	미흡 경영진 의견을 그대로 인용

5. 프롬프트 설계

("system",

"너는 삼성전자 재무/사업보고서 전문 애널리스트이자 데이터 시각화 디자이너다. "

"주어진 컨텍스트만 근거로 사실을 서술하라. 숫자에는 단위/연도를 명확히 붙이고, "

"분석 요청 시 전문적인 리포트를 작성하라. "

"경영진의 의견/전망은 홍보적 수사일 수 있으므로 **숫자·주식 등 근거가 있는 경우에만 인용**하고, "

"근거가 약하면 '경영진 주장'으로 명시하고 **반례·불확실성·리스크**를 함께 기술하라. "

"대시보드는 **JSON 스펙으로만** 출력한다. "

"반드시 아래 JSON 스키마를 따르며, **코드블록 없이 JSON 객체 하나만** 반환한다."),

...

환각현상 제거

- LLM이 사실과 다른 내용을 지어내지 않고, **주어진 데이터만**을 근거로 분석

전문성 부여

- 단순한 질의응답을 넘어, **재무/사업보고서 전문 애널리스트의 시각**으로 심층적인 리포트 작성


비판적 사고 유도

- 경영진의 의견을 맹목적으로 인용하지 않고, 근거가 부족할 경우 **비판적인 관점을 추가**하여 정보의 신뢰도 확보


정형 데이터 출력

- 텍스트 형태의 답변 대신, **차트/표를 그리기 위한 JSON 스펙**을 생성하게 하여 LLM의 결과물을 시스템에 바로 연동

6. QA 시스템 개발



사용자 질문 입력




질문 임베딩

- E5로 벡터화
- 질문의 의미를 수치공간에 표현



문서검색

- 감사보고서 외 추가문서 (사업보고서) 함께 검색

프롬프트 구성
및 LLM 응답 생성

결과 반환 (답변생성)


- 필요 시 그래프/표 시각화도 함께 제공



RAG 기반 QA 시스템 개발



최종결과 및 시연



연구의의 및 한계

연구의의

금융 특화 QA 시스템 구축

재무제표·감사보고서 등
금융 도메인 질의응답 성능 강화

성능 검증 통한 신뢰성 확보

임베딩 모델 비교분석을 통한 선정과
재랭킹·메타데이터 활용으로 답변 정확도 향상

실무 적용 가능성 제시

금융기관·회계업무에서
문서 기반 QA 자동화 활용 기대

연구한계

데이터와 평가 범위의 제한

삼성전자 단일 기업, 2014-2024년 데이터,
소규모 골든셋(50문항)에 국한

수치 질의 및 전처리 한계

수치 연산·연도 비교 질의에서 정확도 저하
HTML 구조 불일치로 인한 데이터 손실 가능

확장성과 일반화의 한계

새로운 보고서 실시간 반영 어려움
다른 산업·기업으로의 일반화 필요

감사합니다

RAG 기반 QA 시스템 개발 _ 4조

